

Laboratorio 4. Parte 2

Analisis de modelos usando datos geoespaciales

Enlace al repositorio: <https://github.com/tismajo/CC3084-Laboratorio4>

1. Preparacion de los datos para Machine Learning

A partir de los rasters de la Parte I, se construyo un conjunto de datos a nivel de pixel para ambos lagos y las mismas 22 fechas (11 por lago) usadas en la Parte I. En el equipo de computo utilizado para este avance, rasterio/GDAL esta bloqueado por una politica de Control de Aplicaciones de Windows (WDAC) a nivel de sistema operativo, por lo que en vez de descargar rasters .tif y leerlos con rasterio, se solicitaron los arreglos directamente a la API de Sentinel Hub (numpy en memoria) mediante un unico evalscript combinado que calcula, para cada pixel: la mascara de agua (mismo criterio WBI de la Parte I), NDVI, NDWI, el indice de cianobacteria (NDCI, Mishra & Mishra, 2012) y las bandas espectrales B02, B03, B04, B05, B08 y B11. Las coordenadas de cada pixel se calcularon por interpolacion lineal sobre el bounding box de cada lago, equivalente a la transformacion afin que usa rasterio para georreferenciar.

Se utilizo una resolucion espacial de 50 m (en vez de los 20 m de la Parte I) para mantener manejable el volumen de datos descargado via API dentro del tiempo disponible, conservando suficiente densidad de pixeles por bloque de ~1 km x 1 km (ver Ejercicio 6).

1.3 Limpieza de observaciones invalidas

Se eliminaron: (1) pixeles fuera del lago segun la mascara de agua (WBI), (2) filas con valores no finitos (NaN/Inf) en NDVI, NDWI o el indice de cianobacteria, producto de divisiones por cero o de pixeles marcados explicitamente como no-agua por la evalscript, y (3) pixeles con NDVI o NDWI fuera del rango matematicamente valido [-1, 1]. De 2,641,584 pixeles totales descargados (todo el bounding box de ambos lagos), quedaron 602,744 observaciones validas de agua.

1.4 Resumen del conjunto de datos

El conjunto final tiene **602,744** observaciones: **538,901** en Atitlan y **63,843** en Amatitlan (11 fechas por lago; ver detalle por fecha en la Tabla 1). Las variables disponibles son: coordenadas (lon, lat), fecha, lago, NDVI, NDWI, indice de cianobacteria (cyano_index) y las bandas B02, B03, B04, B05, B08 y B11 (todas float32, salvo lago y fecha). El porcentaje de valores faltantes es 0.0% en todas las variables, ya que la limpieza del inciso 1.3 elimino previamente cualquier observacion invalida.

lago	fecha	n_observaciones
Amatitlan	2025-01-28	5766
Amatitlan	2025-04-15	5803
Amatitlan	2025-04-28	5799
Amatitlan	2025-11-24	5786
Amatitlan	2026-01-08	5825
Amatitlan	2026-02-02	5793
Amatitlan	2026-02-07	5807
Amatitlan	2026-03-29	5847
Amatitlan	2026-04-13	5910
Amatitlan	2026-04-28	5640
Amatitlan	2026-06-19	5867
Atitlan	2025-01-18	49797
Atitlan	2025-04-13	49077
Atitlan	2025-05-13	49054
Atitlan	2025-07-17	46830
Atitlan	2025-11-21	49178
Atitlan	2025-12-29	49849
Atitlan	2026-02-12	49253
Atitlan	2026-03-24	49109
Atitlan	2026-04-13	48918
Atitlan	2026-04-28	48991
Atitlan	2026-07-22	48845

Tabla 1. Numero de observaciones por lago y fecha, tras la limpieza (Ejercicio 1.3).

1.5 Analisis exploratorio

La Figura 1 muestra la distribucion de NDVI, NDWI y del indice de cianobacteria sobre las 602,744 observaciones (este ultimo recortado al percentil 1-99 solo para la visualizacion, ver nota mas abajo). La Figura 2 compara la distribucion del indice de cianobacteria entre lagos en escala logaritmica: Amatitlan presenta niveles sistematicamente mas altos que Atitlan, consistente con los hallazgos de la Parte I.




Figura 1. Distribucion de NDVI, NDWI y del indice de cianobacteria.




Figura 2. Distribucion del indice de cianobacteria por lago (escala logaritmica, sin outliers).

La Figura 3 muestra la matriz de correlacion entre las bandas espectrales y los indices. Las bandas espectrales estan fuertemente correlacionadas entre si ($r > 0.8$ en la mayoria de los pares), mientras que NDVI y NDWI presentan una correlacion casi perfecta e inversa ($r = -0.94$), como es de esperar dado que ambos se derivan de las mismas bandas (B03, B04, B08).




Figura 3. Matriz de correlacion entre bandas espectrales e indices.

1.6 Decisiones de preparacion y limpieza

(1) Se mantuvieron los mismos lagos, bounding boxes y fechas de la Parte I para que ambas partes sean comparables. (2) Se evito rasterio por el bloqueo WDAC descrito arriba, usando la API de Sentinel Hub directamente. (3) Se redujo la resolucion a 50 m por restricciones de tiempo/computo, manteniendo suficiente detalle para los bloques de 1 km del Ejercicio 6. (4) Se uso la mascara de agua WBI (en vez de un poligono fijo) porque el area de agua cambia ligeramente entre fechas. (5)-(6) Se descartaron valores no finitos y fuera de rango fisico, segun el inciso 1.3. (7) El indice de cianobacteria se conservo identico al de la Parte I (formula NDCI de Mishra & Mishra, 2012), sin recalibrar. (8) A nivel de pixel se observan valores extremos de cyano_index (min -139.5, max 418.4) porque la regresion cubica NDCI->clorofila-a no esta acotada; se documenta como limitacion conocida (ver Ejercicio 10.2) en vez de recortarse arbitrariamente antes de construir la variable respuesta.

2. Construccion de la variable respuesta

2.1 / 2.2 Variable binaria y justificacion del punto de corte

Se definio **alta_cianobacteria = 1** si cyano_index (clorofila-a estimada, ug/L) es mayor o igual a **10 ug/L**, y 0 en caso contrario. El umbral se basa en la bibliografia ambiental consultada:

World Health Organization (2003). Guidelines for Safe Recreational Water Environments. Volume 1: Coastal and Fresh Waters. Cap. 8, Algae and cyanobacteria in fresh water. Ginebra: OMS. Define el Nivel de Alerta 1 (vigilancia) en ~10 ug/L de clorofila-a asociada a cianobacterias (~20,000 celulas/mL), con probabilidad moderada de efectos adversos a la salud, y el Nivel de Alerta 2 en ~50 ug/L (o presencia de acumulaciones

visibles), con probabilidad alta de efectos agudos.

Mishra, S., & Mishra, D. R. (2012). Normalized difference chlorophyll index: A novel model for remote estimation of chlorophyll-a concentration in turbid productive waters. *Remote Sensing of Environment*, 117, 394-406. Fuente del modelo NDCI usado para estimar cyano_index a partir de B04 y B05.

Se adopto el Nivel de Alerta 1 (10 ug/L), en vez del Nivel 2, porque corresponde al umbral minimo en el que la literatura ya reporta riesgo sanitario (vigilancia activa), lo cual es mas util para un sistema de alerta temprana que esperar al escenario extremo de floracion visible.

2.3 / 2.4 Distribucion y desbalance de clases

Globalmente, 7,364 observaciones (1.22%) corresponden a alta presencia y 595,380 (98.78%) a ausencia/baja presencia: una razon de desbalance de **80.9 : 1**. La Tabla 2 muestra que este desbalance es muy distinto entre lagos: Amatitlan tiene una tasa de positivos ~180 veces mayor que Atitlan, reflejando su condicion hipereutrofica frente al regimen oligotrofico de Atitlan.

lago	n_observaciones	n_positivos	tasa_positivos
Amatitlan	63843	7042	11.03
Atitlan	538901	322	0.06

Tabla 2. Distribucion de la variable respuesta por lago.

Consecuencias del desbalance: un modelo entrenado sin ajustes puede maximizar accuracy prediciendo casi siempre la clase mayoritaria (0), logrando accuracy alto pero recall muy bajo para la clase de interes (alta presencia), que es la que mas importa detectar desde el punto de vista de salud publica. Esto exige usar metricas sensibles al desbalance (recall, F1, ROC-AUC) en vez de accuracy, y tecnicas de balanceo (class_weight/scale_pos_weight) al entrenar los modelos (Ejercicio 4).

2.5 Variables excluidas por fuga de informacion

Se excluyen como predictoras: **cyano_index** (es la variable con la que se construye directamente la respuesta), **B04** y **B05** (bandas usadas directamente en el calculo de $NDCI = (B05 - B04) / (B05 + B04)$, que alimenta la formula cubica de cyano_index; incluirlas permitiria al modelo reconstruir casi exactamente la etiqueta). NDVI se calcula tambien con B04, pero al ser una transformacion distinta que no reproduce la relacion NDCI, se mantiene como predictor valido, documentando este riesgo menor de colinealidad indirecta.

3. Seleccin y construccion de variables predictoras

El conjunto final de predictores excluye cyano_index, B04, B05 (Ejercicio 2.5) y las columnas de metadatos (lon, lat, lago, fecha), que se conservan unicamente para la validacion espacial/temporal y los experimentos de generalizacion entre lagos (Ejercicios 6 y 7), pero no se usan como predictores para evitar que el modelo memorice la ubicacion o la fecha en vez de aprender un patron espectral.

variable	descripcion
ndvi	Indice de vegetacion de diferencia normalizada. Aunque fue disenado para vegetacion terrestre, sobre cuerpos de agua valores de NDVI menos negativos/positivos pueden indicar vegetacion acuatica flotante o acumulaciones algales superficiales densas.
ndwi	Indice de agua de diferencia normalizada. Indica el grado de 'pureza' espectral del agua; caidas en NDWI dentro del cuerpo de agua pueden reflejar interferencia de material en suspension, incluidas floraciones algales.
B02	Banda azul (490 nm). Sensible a dispersion por particulas finas en suspension y turbidez del agua; ayuda a distinguir aguas claras de aguas con alta carga de solidos/algas.
B03	Banda verde (560 nm). Es la banda mas sensible a la reflectancia de la clorofila-a en el agua; valores altos de reflectancia verde suelen asociarse a mayor biomasa algal.
B08	Banda infrarroja cercana (NIR, 842 nm). El agua absorbe fuertemente el NIR, pero la presencia de biomasa algal o material organico en la superficie aumenta la reflectancia NIR respecto a agua limpia; util para detectar acumulaciones superficiales densas.
B11	Banda infrarroja de onda corta (SWIR1, 1610 nm). Aporta informacion sobre contenido de humedad/materia organica y ayuda a discriminar agua de vegetacion flotante o sedimentos.
ratio_verde_azul	B03/B02. Proxy alternativo (no basado en B04/B05) de biomasa algal: la clorofila-a incrementa la reflectancia verde relativa a la azul.
brillo_superficial	Promedio de B02, B03 y B08. Floraciones densas en superficie tienden a elevar la reflectancia total respecto a agua limpia.
indice_turbidez_verde_swir	$(B03-B11)/(B03+B11)$. Contraste entre la banda mas sensible a pigmentos (verde) y la banda sensible a materia organica/humedad (SWIR1), como proxy adicional de turbidez.

Tabla 3. Variables predictoras seleccionadas y su justificacion.

Las tres ultimas filas de la Tabla 3 (ratio_verde_azul, brillo_superficial, indice_turbidez_verde_swir) son variables de ingenieria de caracteristicas creadas a partir de bandas sin riesgo de fuga: **ratio_verde_azul** (B03/B02) es un proxy de biomasa algal alternativo a NDCI; **brillo_superficial** (promedio de B02, B03, B08) captura acumulaciones densas en superficie; **indice_turbidez_verde_swir** $((B03-B11)/(B03+B11))$ contrasta la banda mas sensible a pigmentos con la banda sensible a materia organica/humedad, como proxy adicional de turbidez.

4. Construcción de modelos de Machine Learning

Se construyeron tres modelos de clasificación: Regresión Logística, Random Forest y XGBoost, usando los 9 predictores del Ejercicio 3. Los datos se dividieron de forma estratificada en 70% entrenamiento (421,920 obs.) y 30% prueba (180,824 obs.), preservando la proporción de 1.222% de positivos en ambos subconjuntos (dado el fuerte desbalance del Ejercicio 2.4). El mismo conjunto de prueba se reutiliza en todo el Ejercicio 5 para comparar los modelos de forma justa.

Para compensar el desbalance sin sobre/submuestrear, se usó `class_weight="balanced"` (Regresión Logística, Random Forest) y `scale_pos_weight` igual a la razón de clases (XGBoost).

4.3 Ajuste de hiperparámetros

Se usó `RandomizedSearchCV` (`scoring=F1`, `cv=3`) sobre una submuestra estratificada de 80,000 filas del entrenamiento, para mantener manejable el tiempo de búsqueda dado el tamaño del conjunto completo (~420k filas). F1 se prioriza sobre `accuracy` por el desbalance de clases. La mejor configuración de cada modelo se reentreno después sobre el conjunto de entrenamiento completo. La Tabla 4 resume los hiperparámetros probados y seleccionados.

modelo	mejores_hiperparametros	f1_cv_submuestra
logistic_regression	{ <code>C</code> : 100}	0.480
random_forest	{ <code>n_estimators</code> : 100, <code>min_samples_leaf</code> : 1, <code>max_depth</code> : None}	0.854
xgboost	{ <code>n_estimators</code> : 300, <code>max_depth</code> : 7, <code>learning_rate</code> : 0.1}	0.854

Tabla 4. Hiperparámetros seleccionados por `RandomizedSearchCV` (`scoring=F1`, `cv=3`) y F1 obtenido en validación cruzada sobre la submuestra.

Random Forest y XGBoost alcanzan F1~0.85 en validación cruzada, muy por encima de Regresión Logística (F1~0.48), anticipando que los modelos de árbol capturan mejor la relación no lineal entre las variables espectrales y la presencia de cianobacteria.

5. Evaluacion de los modelos

5.1 / 5.2 Metricas y comparacion de modelos

modelo	accuracy	precision	recall	f1	f2	roc_auc
logistic_regression	0.978	0.352	0.975	0.517	0.720	0.996
random_forest	0.997	0.871	0.900	0.885	0.894	0.997
xgboost	0.996	0.787	0.938	0.855	0.903	0.999

Tabla 5. Metricas de los tres modelos sobre el conjunto de prueba (70/30 estratificado).

Regresion Logistica			Random Forest			XGBoost		
	pred_0	pred_1		pred_0	pred_1		pred_0	pred_1
real_0	174643	3972	real_0	178322	293	real_0	178053	562
real_1	55	2154	real_1	222	1987	real_1	138	2071

Tabla 6. Matrices de confusion de los tres modelos sobre el conjunto de prueba.

Random Forest obtiene el mejor F1 (0.885) y XGBoost el mejor ROC-AUC (0.999) y el mejor recall (0.938); Regresion Logistica logra recall alto (0.975) pero precision muy baja (0.352), generando 3,972 falsas alarmas de 178,615 negativos reales.

5.3 Analisis ambiental de los errores

Falso positivo (predecir alta presencia sin haberla): cierre preventivo o alerta innecesaria, con costo economico/turistico y perdida de confianza en el sistema si se repite; costo principalmente operativo y reversible. Falso negativo (no detectar una zona con alta presencia): exposicion sin advertencia a cianobacterias potencialmente toxicas, con riesgo de efectos agudos a la salud (irritacion de piel/mucosas, problemas gastrointestinales y, en casos severos, efectos hepatotoxicos o neurotoxicos); costo sobre salud publica, potencialmente irreversible.

Dado que el falso negativo es claramente mas grave, se prioriza el recall, usando F2-score (fbeta con beta=2, que pondera el recall el doble que la precision) como metrica de comparacion. Bajo este criterio, XGBoost es el mejor modelo (F2=0.903), preferido sobre Random Forest pese a que este ultimo tiene mejor F1, porque XGBoost detecta una proporcion mayor de las zonas realmente criticas (recall 0.938 vs 0.900).

6. Validacion espacial

6.1 / 6.2 Cuadrícula de 1km x 1km

Las observaciones se reprojectaron a EPSG:32615 (WGS84 / UTM zona 15N) y se dividieron en bloques de 1 km x 1 km por lago. La Tabla 6 confirma que este tamaño produce suficientes bloques con observaciones validas: 266 bloques en Atitlan (~2,026 obs./bloque en promedio) y 50 en Amatitlan (~1,277 obs./bloque), por lo que no fue necesario ajustar el tamaño de bloque.

lago	n_bloques	obs_promedio_p or_bloque	obs_mediana_po r_bloque	obs_min_por_blo que	obs_max_por_bl oque
Amatitlan	50	1276.9	732.0	1.0	4400.0
Atitlan	266	2025.9	1363.0	1.0	4620.0

Tabla 7. Resumen de bloques espaciales de 1km x 1km por lago.




Figura 4. Bloques espaciales de 1km x 1km en Atitlan (color = bloque).




Figura 5. Bloques espaciales de 1km x 1km en Amatitlan (color = bloque).

6.3-6.6 Validacion cruzada espacial vs. aleatoria

Se comparo StratifiedKFold (aleatoria, 5 folds) contra GroupKFold por bloque de 1km (espacial, 5 folds), usando los mismos hiperparametros del Ejercicio 4.3 para los tres modelos, de modo que la unica diferencia entre esquemas sea como se agrupan las observaciones.

modelo	metrica	aleatoria	espacial	diferencia_espacial_menos_aleatoria
logistic_regression	f1	0.4854	0.4875	0.0021
logistic_regression	precision	0.3245	0.3351	0.0107
logistic_regression	recall	0.9737	0.9702	-0.0035
logistic_regression	roc_auc	0.9923	0.9925	0.0002
random_forest	f1	0.8904	0.8687	-0.0217
random_forest	precision	0.8715	0.8581	-0.0133
random_forest	recall	0.9102	0.8802	-0.0300
random_forest	roc_auc	0.9966	0.9953	-0.0013
xgboost	f1	0.8515	0.8260	-0.0255
xgboost	precision	0.7767	0.7514	-0.0253
xgboost	recall	0.9424	0.9222	-0.0202
xgboost	roc_auc	0.9991	0.9985	-0.0006

Tabla 8. Comparacion de metricas medias (5 folds) entre validacion aleatoria y espacial.

Random Forest y XGBoost caen consistentemente bajo validacion espacial (recall -0.030 y -0.020 respectivamente; F1 -0.022 y -0.025), mientras que Regresion Logistica se mantiene practicamente igual. Esto ocurre porque, en la validacion aleatoria, pixeles vecinos casi identicos (por autocorrelacion espacial) pueden quedar repartidos entre entrenamiento y prueba, inflando artificialmente el desempeno reportado. La

validacion espacial obliga al modelo a predecir sobre bloques geograficos nunca vistos, lo cual es una estimacion mas realista de su capacidad de generalizar a zonas nuevas del lago, que es para lo que se usaria en la practica un sistema de monitoreo.

7. Generalizacion entre lagos

Se reutilizaron los mismos hiperparametros del Ejercicio 4.3 en cuatro escenarios: Experimento A (entrenar con Atitlan, evaluar con Amatitlan), Experimento B (entrenar con Amatitlan, evaluar con Atitlan), y dos escenarios de referencia con entrenamiento y prueba dentro del mismo lago.

escenario	modelo	precision	recall	f1	roc_auc
A_train_Atitlan_test_Amatitlan	logistic_regression	0.137	0.996	0.240	0.927
A_train_Atitlan_test_Amatitlan	random_forest	0.130	0.001	0.002	0.681
A_train_Atitlan_test_Amatitlan	xgboost	0.694	0.122	0.208	0.751
B_train_Amatitlan_test_Atitalan	logistic_regression	0.057	0.733	0.105	0.868
B_train_Amatitlan_test_Atitalan	random_forest	0.309	0.078	0.124	0.856
B_train_Amatitlan_test_Atitalan	xgboost	0.221	0.189	0.204	0.903
mismo_lago_Atitalan	logistic_regression	0.047	0.948	0.090	0.993
mismo_lago_Atitalan	random_forest	0.500	0.454	0.476	0.963
mismo_lago_Atitalan	xgboost	0.316	0.515	0.392	0.994
mismo_lago_Amatitlan	logistic_regression	0.678	0.955	0.793	0.981
mismo_lago_Amatitlan	random_forest	0.889	0.929	0.908	0.995
mismo_lago_Amatitlan	xgboost	0.885	0.934	0.909	0.996

Tabla 9. Metricas de los experimentos de generalizacion entre lagos y de referencia (mismo lago).

7.5 Un modelo entrenado en un lago NO generaliza adecuadamente al otro. En ambas direcciones el desempeno cae drasticamente frente al escenario de mismo lago: Random Forest pasa de recall=0.454 (mismo lago, Atitlan) a recall=0.001 al evaluarse en Amatitlan tras entrenarse solo en Atitlan; XGBoost pasa de recall=0.934 (mismo lago, Amatitlan) a recall=0.122-0.189 en los experimentos cruzados. Regresion Logistica es la excepcion parcial: mantiene recall alto entre lagos, pero unicamente porque predice positivo con mucha mas frecuencia (precision tan baja como 0.057-0.137), no porque capture un patron transferible.

7.6 Posibles causas: (1) linea base ecologica muy distinta -Amatitlan hipereutrofico con floraciones frecuentes (~11% positivos) vs. Atitlan oligotrofico con floraciones raras (~0.06% positivos)-; (2) rango de valores espectrales distinto entre lagos incluso sin cianobacteria (covariate shift, por diferencias de profundidad, geologia y entorno urbano/agricola); (3) desbalance extremo en Atitlan (solo 322 pixeles positivos en toda la serie), que deja muy poca senal para aprender un patron generalizable. Conclusion practica: se necesita un modelo (o al menos un recalibrado de umbral) especifico por lago, en vez de un unico modelo aplicado a ambos.

8. Interpretacion y explicabilidad del modelo

8.1 Importancia global de variables

Para el modelo seleccionado (XGBoost), la Figura 6 muestra que **ratio_verde_azul** (la variable de ingeniería de características del Ejercicio 3.3) domina ampliamente la importancia global (0.79 de 1.0 en importancia relativa), muy por encima de NDVI (0.08) y del resto de variables.




Figura 6. Importancia global de variables (XGBoost).

8.2-8.4 SHAP e interpretacion ambiental




Figura 7. SHAP summary plot del modelo XGBoost (muestra de 3,000 observaciones de prueba).

variable	importancia_media_abs_shap	correlacion_valor_vs_shap	direccion
ratio_verde_azul	6.128	0.956	valores altos -> mayor prob. alta cianobacteria
ndvi	2.791	0.672	valores altos -> mayor prob. alta cianobacteria
B02	1.013	-0.466	valores altos -> menor prob. alta cianobacteria
brillo_superficial	0.816	0.465	valores altos -> mayor prob. alta cianobacteria
ndwi	0.783	0.901	valores altos -> mayor prob. alta cianobacteria
B03	0.699	0.215	valores altos -> mayor prob. alta cianobacteria
B11	0.638	-0.144	valores altos -> menor prob. alta cianobacteria
indice_turbidez_verde_swir	0.521	0.039	valores altos -> mayor prob. alta cianobacteria
B08	0.335	-0.158	valores altos -> menor prob. alta cianobacteria

Tabla 10. Importancia media |SHAP| y direccion del efecto por variable.

ratio_verde_azul es, por amplio margen, la variable mas influyente (correlacion valor-SHAP +0.96): a mayor reflectancia verde relativa a la azul, mayor probabilidad de alta cianobacteria, consistente con que los pigmentos fotosinteticos (clorofila-a, ficocianina) incrementan la reflectancia verde mientras el agua limpia dispersa relativamente mas azul. NDVI (+0.67) y NDWI (+0.90) tambien empujan la prediccion hacia 'alta presencia' cuando son altos; dentro de pixeles YA clasificados como agua, ambos quedan dominados por el mismo contraste verde-vs-resto que ratio_verde_azul, por lo que 'NDWI alto' aqui refleja mayor reflectancia verde (pigmentos), no necesariamente 'agua mas pura'. B02 (azul, -0.47) y B08 (NIR, -0.16) muestran el patron opuesto: mayor reflectancia empuja hacia 'baja presencia', coherente con que el agua limpia dispersa mas azul y absorbe mas NIR que el agua con biomasa algal densa. En conjunto, el modelo aprende un patron ambientalmente plausible, dominado por un unico mecanismo fisico (contraste verde-azul asociado a pigmentos fotosinteticos).

9. Generacion de mapas predictivos

Se calculo, con el modelo XGBoost, la probabilidad de alta presencia de cianobacteria para cada observacion, y se reconstruyo espacialmente en un mapa por lago, para la fecha con mayor tasa de positivos observada en el Ejercicio 2.3 (Atitlan: 2026-07-22; Amatitlan: 2026-06-19), usando una escala discreta de 4 niveles (muy baja, baja, alta, muy alta).




Figura 8. Mapa de probabilidad de alta presencia de cianobacteria - Amatitlan, 2026-06-19.




Figura 9. Mapa de probabilidad de alta presencia de cianobacteria - Atitlan, 2026-07-22.

9.5 Comparacion con la Parte I: para las mismas fechas, el mapa de probabilidad reproduce con buena fidelidad visual las zonas de mayor clorofila-a de la Parte I: en Amatitlan, el brazo norte y la bahia sureste aparecen como 'muy alta' probabilidad, coincidiendo con las zonas de mayor clorofila-a (amarillo) del mapa original de la Parte I; el tramo central, con clorofila baja en la Parte I, aparece consistentemente como 'muy baja' en el mapa predictivo.

lago	fecha	FN (no detectada)	FP (falsa alarma)	TN (acierto en baja presencia)	TP (acierto en alta presencia)
Amatitlan	2026-06-19	24	364	2348	3131
Atitlan	2026-07-22	6	43	48721	75

Tabla 11. Conteo de aciertos y errores espaciales (umbral de decision 0.5) para las fechas representativas.




Figura 10. Aciertos y errores espaciales - Amatitlan, 2026-06-19.




Figura 11. Aciertos y errores espaciales - Atitlan, 2026-07-22.

9.6 / 9.7 Patrones espaciales de error: los falsos positivos y falsos negativos no se distribuyen de forma uniforme, sino que se concentran en los **bordes** entre zonas de alta y baja concentracion (ver el halo naranja

de falsas alarmas alrededor de las zonas verdes de acierto en la Figura 10), donde el valor real de clorofila-a esta cerca del umbral de decision (10 ug/L) y pequenas variaciones de reflectancia bastan para cambiar la clase predicha. El modelo tiene mas dificultad en la frontera de las floraciones que en su nucleo (valores muy altos, facilmente separables) o en zonas claramente limpias (valores muy bajos); la resolucion espacial de 50 m tambien contribuye a este ruido de borde.

10. Analisis y conclusiones

10.1 Capacidad del modelo como herramienta de apoyo

El modelo final (XGBoost) alcanza en el conjunto de prueba (division aleatoria 70/30): recall=0.938, precision=0.787, F1=0.855, ROC-AUC=0.999. Bajo validacion espacial (GroupKFold por bloque de 1 km), el recall se mantiene alto (0.922), lo que indica que el modelo SI tiene capacidad util como herramienta de **apoyo** al monitoreo: detecta la gran mayoria de las zonas con alta presencia (pocos falsos negativos, el error mas costoso segun el Ejercicio 5.3), a costa de generar tambien falsas alarmas que un equipo humano deberia poder descartar con verificacion rapida. Sin embargo, esta capacidad es condicional: funciona bien DENTRO de un mismo lago, pero el Ejercicio 7 mostro que NO generaliza de un lago a otro (recall tan bajo como 0.001-0.19 en los experimentos cruzados). Por lo tanto, el modelo es util como apoyo al monitoreo siempre que se entrene y aplique de forma especifica para cada lago, y no deberia usarse como sustituto de muestreos fisicos de confirmacion, sino como sistema de priorizacion de zonas a inspeccionar.

10.2 Limitaciones encontradas

(1) Solo 11 fechas por lago, distribuidas de forma irregular a lo largo de ~1.5 anios, lo que limita capturar la dinamica temporal completa de las floraciones. (2) Nubosidad y pixeles invalidos: varias fechas muestran menos pixeles de agua validos que otras. (3) Resolucion espacial reducida (50 m vs. 20 m de la Parte I) por restricciones de computo, que pudo suavizar patrones finos de floracion. (4) Diferencias extremas entre lagos: Atitlan tiene apenas 322 pixeles positivos en toda la serie (0.060%) frente a una tasa mucho mayor en Amatitlan, por lo que cualquier metrica agregada esta dominada por Amatitlan. (5) Metodologia de validacion: la validacion aleatoria sobreestima el desempeno respecto a la espacial, y el modelo no generaliza entre lagos, por lo que las metricas solo son validas para el lago en el que se entreno. (6) cyano_index es un proxy espectral (NDCI), no una medicion de laboratorio, y hereda las limitaciones de cualquier estimacion remota (valores extremos no acotados).

10.3 Datos adicionales que podrian mejorar el modelo

(1) Variables meteorologicas: precipitacion y temperatura (ver los enlaces de weatherspark.com sugeridos en el enunciado para Amatitlan y Santiago Atitlan), que podrian explicar parte de la variabilidad temporal de las floraciones. (2) Variables hidrologicas: nivel del lago, tiempo de residencia del agua, aportes de afluentes y descargas de aguas residuales (relevante sobre todo para Amatitlan). (3) Mayor frecuencia temporal (cadencia semanal en vez de huecos de varios meses), para capturar el ciclo completo de una floracion. (4) Muestreos fisicos de calibracion (clorofila-a, ficocianina o conteo celular de laboratorio) para validar el proxy NDCI actualmente usado. (5) Bandas espectrales adicionales (borde rojo B06/B07) o indices especificos de ficocianina, pigmento distintivo de cianobacterias. (6) Modelos o umbrales especificos por lago, dado que un unico modelo no generaliza entre lagos (Ejercicio 7).